DSMarket TFM — Clustering & Forecasting

Grupo 2 · DS&IA 0925 · Resumen para reunión con tutor

Marzo 2026
30 min · Notebook final
Grupo_2_dscesp_0925_tfm_ds_market

1. CONTEXTO Y OBJETIVO DEL PROYECTO

DSMarket es una cadena de retail con **10 tiendas** en 3 ciudades (New York, Boston, Philadelphia), **3.049 productos** en 3 categorías y datos de ventas diarias desde **enero 2011 hasta abril 2016** (~59M registros).

OBJETIVO PRINCIPAL

Predecir demanda diaria por producto y tienda

Para optimizar abastecimiento

DATASET TOTAL

~59M

filas · 10 tiendas · 3.049 productos

PERÍODO CUBIERTO

5.3 años

Ene 2011 → Abr 2016

Flujo del proyecto: EDA → Análisis ACF/PACF → Feature Engineering → **Clustering** (productos + tiendas) → **Forecasting** (6 modelos + Optuna) → Sistema de Abastecimiento

2. CLUSTERING — SEGMENTACIÓN DE PRODUCTOS Y TIENDAS

Objetivo del clustering: Identificar grupos homogéneos de productos y tiendas para personalizar estrategias de reposición y comprender patrones de demanda. No se usa como feature del modelo ML, sino como herramienta de análisis de negocio.

2.0 Métricas de evaluación del clustering — cómo interpretarlas

KMeans no tiene una métrica de error directa como los modelos supervisados. Se usan dos métricas complementarias para elegir el k óptimo:

SILHOUETTE SCORE — CUANTO MÁS ALTO MEJOR

Rango: −1 → +1

Mide qué tan bien encaja cada punto en su propio cluster comparado con los demás clusters.

+1 → el punto está muy cerca de su cluster y lejos de los otros (clusters perfectamente separados)
0 → el punto está en el borde entre dos clusters (ambigüedad)
−1 → el punto encaja mejor en otro cluster (asignación incorrecta)

Referencia práctica: >0.50 excelente · 0.25–0.50 razonable · <0.25 clusters débiles

INERCIA (WCSS) — CUANTO MÁS BAJA MEJOR

Rango: 0 → ∞

Suma de distancias al cuadrado de cada punto a su centroide (Within-Cluster Sum of Squares).

Problema: siempre baja al aumentar k — con k = número de puntos, inercia = 0.
Por eso se usa el **Elbow Method**: se busca el "codo" donde la reducción de inercia se vuelve marginal.

No se interpreta de forma absoluta — solo tiene sentido comparando distintos k entre sí.

¿Por qué usar ambas? La inercia siempre mejora con más k (sesgada hacia k grande). El Silhouette Score penaliza k demasiado grande si los clusters resultantes son artificiales. Usarlas juntas evita elegir un k innecesariamente complejo: se busca el k donde el *Silhouette es máximo* y la *reducción de inercia ya no justifica añadir más clusters*.

2.1 Clustering de Productos (KMeans)

FEATURES UTILIZADAS

- **avg_daily_sales** — Ventas promedio diarias del producto
- **cv_sales** — Coeficiente de variación (std/media) → mide irregularidad de demanda
- **avg_price / std_price** — Precio medio y variabilidad (descuentos)
- **weekend_boost** — Ratio ventas fin de semana vs días laborables
- **event_sensitivity** — Ratio ventas en días de evento vs sin evento

Normalización previa con **StandardScaler** para evitar que avg_daily_sales domine por escala.

PASO 1 — DETERMINACIÓN DEL RANGO DE K (ELBOW + SILHOUETTE SOBRE K=2..12)

La regla heurística **$k \approx \sqrt{(n/2)}$** con n=3.049 productos daría k≈39 clusters — inmanejable operativamente. En su lugar se evaluó el rango k=2..12 usando **MiniBatchKMeans** sobre los 3.049 productos con dos métricas complementarias:

Elbow Method
La inercia desciende pronunciadamente hasta **k=6**, donde KneeLocator detecta el codo (punto de inflexión). A partir de k=6 cada cluster adicional reduce la inercia marginalmente (~200–400 puntos vs ~1.000–2.000 antes del codo).

Silhouette Score
Pico en k=2 (0.21), con un segundo máximo local en **k=7** (0.187). Descenso generalizado a partir de k=8 (caída pronunciada en k=10), indicando que clusters más pequeños empiezan a solaparse.

Valores de silhouette en torno a 0.17–0.21 son esperables en datos de retail item-día, donde los perfiles no son perfectamente separables (misma cadena, misma política de precios).

Rango seleccionado para evaluación detallada: k ∈ {5, 6, 7} — convergencia entre el codo (k=6) y el segundo máximo de silhouette (k=7), con k=5 como valor adyacente inferior.

PASO 2 — EVALUACIÓN DETALLADA K ∈ {5, 6, 7}

k	Silhouette Score ↑	Inercia ↓	Veredicto
k = 5	**0.2249**	**10.420**	✓ ELEGIDO — mejor separación
k = 6	0.1937	9.475	Silhouette cae -13% vs k=5
k = 7	0.1936	8.813	Sin mejora respecto a k=6

Decisión: k = 5. Mayor Silhouette Score (0.2249): los clusters están mejor definidos y separados. La reducción de inercia de k=5 a k=6 (~950 puntos, -9%) no compensa la pérdida de cohesión interna (-13% en silhouette). k=6 y k=7 producen silhouettes prácticamente idénticos (0.1937 vs 0.1936), confirmando que el 6º y 7º cluster no aportan nueva información. 5 perfiles es además operativamente manejable para el equipo de negocio.

LOS 5 CLUSTERS RESULTANTES

★ Cluster 4
Productos Estrella

Ventas/día: **11.84** (10× resto)

CV: 1.18 — muy estables

Precio: 1.81€ (más bajo)

93% SUPERMARKET

Alta rotación, baja variabilidad y precio bajo. Son los productos de primera necesidad que sostienen el volumen de ventas. Cualquier rotura de stock impacta directamente en ingresos → stock permanente sin excepción.

Cluster 1
Regulares Supermercado

Ventas/día: **1.34**

CV: 1.73 — variabilidad media

Precio: 3.87€

61% SUPERMARKET

Demanda constante y predecible. Representan el grueso del catálogo. El modelo ML predice bien este grupo gracias a su regularidad → gestión automática por umbral de reposición.

Cluster 0
Fin de Semana

Ventas/día: **0.43**

Weekend boost: **1.45×**

CV: 2.79 — irregular

52% HOME & GARDEN

Venden un 45% más en fin de semana. Productos de hogar/jardín ligados al ocio. Reponer entre semana falla porque la demanda pico es el sábado → anticipar pedido los jueves.

Cluster 3
Premium / Promocional

Precio: **14.76€** (el más alto)

std_price: 0.81 (más descuentos)

CV: 2.48 — variable

Precio alto con alta variación → promociones frecuentes que disparan la demanda puntualmente. La demanda no es estable sino reactiva al precio → el modelo necesita sell_price como feature clave para este grupo.

Cluster 2
Demanda Intermitente

Ventas/día: **0.23** (mínimo)

CV: **3.53** (máximo)

Muy erráticos

Venden menos de 1 unidad cada 4 días con demanda impredecible. El modelo ML tiene más error en este grupo (alto MAPE). No se justifica stock permanente → pedido bajo demanda o revisión de si el producto debe seguir en catálogo.

2.2 Clustering de Tiendas (KMeans)

FEATURES UTILIZADAS — MISMAS QUE PRODUCTOS PERO A NIVEL TIENDA

avg_daily_sales, cv_sales, avg_price, weekend_boost, event_sensitivity · Normalización: StandardScaler

SELECCIÓN DEL K ÓPTIMO — POR QUÉ EXACTAMENTE K = 2, 3 Y 5

Con solo **10 tiendas** la elección de k está muy restringida. La regla general es **k ≤ n/2** para garantizar al menos 2 elementos por cluster (con 10 tiendas, máximo k=5). Dentro de ese límite, se eligieron estos tres valores por razones específicas:

k evaluado	Razonamiento
k = 2	Mínimo posible con sentido: separa las tiendas en dos grandes grupos (alto vs bajo rendimiento). Sirve como referencia de si existen diferencias básicas entre tiendas.
k = 3	Hipótesis de negocio: DSMarket opera en **3 ciudades** (New York, Boston, Philadelphia). Si el comportamiento de las tiendas está determinado por su ciudad, k=3 debería revelar exactamente esa estructura. Se evaluó para confirmar o refutar esta hipótesis.
k = 5	Máximo permitido por la regla k ≤ n/2. Con 10 tiendas, k=5 da exactamente 2 tiendas por cluster de media — el límite inferior de representatividad estadística.

Se omitió k=4 porque no tiene una interpretación natural (no corresponde a ciudades ni a ninguna agrupación geográfica o de negocio conocida). Los resultados confirmaron la hipótesis: k=3 obtuvo el mejor Silhouette y los clusters coinciden con las 3 ciudades.

k	Silhouette Score ↑	Inercia ↓	Veredicto
k = 2	0.2660	31	Buena separación, poca granularidad
k = 3	**0.2928**	**21**	✓ELEGIDO — mejor separación

k = 5	0.2556	9	Peor que k=3, grupos muy pequeños

Decisión: k = 3. Mejor Silhouette Score (0.2928). Además, k=3 tiene una interpretación natural: las 10 tiendas operan en 3 ciudades (New York 4, Boston 3, Philadelphia 3). El resultado confirma que la **ubicación geográfica es el principal factor diferenciador** del comportamiento de ventas. Aumentar a k=5 empeora la separación (0.2556), lo que indica que grupos más pequeños ya no tienen coherencia real.

LOS 3 CLUSTERS RESULTANTES

Cluster 1 — Alto Volumen

avg_daily_sales: **1.26**

CV: 3.56 — más errático

60% Boston (3 tiendas)

Las tiendas de Boston lideran en ventas pero son las más erráticas. Mayor volumen implica mayor riesgo de rotura → son las que más se benefician del sistema de reposición automática y las predicciones del modelo.

Cluster 2 — Fin de Semana

avg_daily_sales: 1.07

Weekend boost: **1.44×**

67% New York

Las tiendas de Nueva York presentan un patrón de consumo marcadamente de fin de semana (+44%). La reposición semanal estándar no es válida aquí → requiere ciclo de reposición corto alineado al pico del sábado.

Cluster 0 — Baja Actividad

avg_daily_sales: **0.92**

Event sensitivity: 0.87

NY 50% + Philadelphia 50%

Tiendas con menor demanda diaria y alta sensibilidad a eventos externos. Volumen bajo significa menor urgencia de reposición, pero sus picos son impredecibles. El modelo tiene más incertidumbre en este grupo → revisar surtido y ajustar safety stock.

Nota sobre los Silhouette Scores: Valores entre 0.25–0.30 indican diferencias comportamentales *sutiles pero reales*. Es esperable en una cadena homogénea (mismos productos, misma política de precios). No son clusters perfectamente separados, pero sí con características diferenciadas y accionables.

3. FORECASTING — PREDICCIÓN DE DEMANDA

3.1 Feature Engineering (37 variables)

Antes de modelar, se construyeron features temporales, de lag, rolling y de precio. La selección de lags se basó en el **análisis ACF/PACF**:

- ACF muestra autocorrelación significativa hasta lag 40 → *serie con mucha memoria temporal*
- PACF muestra contribución directa alta en lag 1 (≈0.78) → lag_1 es el predictor más potente
- Patrones semanales en lags 7, 14, 21, 28 → ciclos de 1, 2, 3 y 4 semanas

Grupo	Features	Justificación
Lag	sales_lag_1/7/14/21/28	Memoria temporal — ventas pasadas predicen futuras
Rolling	rolling_mean_7/14/28 · rolling_std_7/14/28 · max/min_28	Tendencia reciente y variabilidad
Temporal	weekday_int · is_weekend · month · week_of_year · is_event	Estacionalidad semanal/mensual y eventos
Precio	sell_price · price_lag_1 · price_change · price_rolling_mean_4w	Elasticidad precio-demanda
Agregados	item_avg_sales · store_avg_sales · category/city_avg	Nivel base de demanda por entidad
Encoding	item/store/category/dept/city encoded	Identidad de producto y tienda

3.2 Split Temporal — por qué no cross-validation

Conjunto	Período	Filas
Train	Ene 2011 → Feb 2016	57.442.786
Test	Mar 2016 (28 días)	854.616
Validation	**Abr 2016 (28 días)**	**853.720**

¿Por qué split temporal?
En series temporales el futuro depende del pasado. Si mezclamos fechas en cross-validation, el modelo vería datos futuros durante el entrenamiento (data leakage), obteniendo métricas artificialmente optimistas. El split cronológico garantiza que *siempre predecimos hacia adelante*, igual que en producción.

3.3 Baseline — Media Móvil 28 días

El baseline usa la media de los 28 días anteriores como predicción (rolling_mean_28). Se eligió este umbral porque captura exactamente **4 ciclos semanales completos**, siendo el predictor estadístico más simple con sentido de negocio. Si los modelos ML no superan este baseline, el ejercicio carece de valor.

RMSE baseline: 2.1847 · MAE: 1.0048 · MAPE: 58.74%

3.4 Comparativa de Modelos

Baseline MA28	Ridge	Random Forest	CatBoost	LightGBM	XGBoost	🏆 XGBoost+Optuna
2.1847	2.0647	2.0101	1.9752	1.9674	1.9673	1.9645
Referencia	+5.5%	+8.0%	+9.6%	+9.9%	+9.9%	TEST · +10.1%

Modelo	RMSE (Test)	MAE (Test)	MAPE (Test)	Tiempo	Observación clave
Baseline MA28	2.1847	1.0048	58.74%	—	Referencia mínima
Ridge	2.0647	0.9972	59.26%	239s	Confirma que las features aportan valor
Random Forest	2.0101	0.9733	55.95%	2.094s	n_estimators=50, muestra 5% por limitación RAM
CatBoost	1.9752	0.9613	56.46%	3.369s	Maneja categóricas nativas, ordered boosting
LightGBM	1.9674	0.9600	56.49%	3.896s	Best iter 999/1000, lento por bagging en 57M
XGBoost	1.9673	0.9590	56.20%	1.428s	**Best iter 998/1000 → margen mejora con Optuna**
XGBoost+Optuna ★	**1.9645**	**0.9580**	**56.31%**	**1,839s (~31min)**	**Ganador en TEST · reentrenado sobre 57M filas**

★ XGBoost+Optuna evaluado en Validación (conjunto independiente, Mar–Abr 2016): RMSE **1.8994** · MAE 0.9592 · MAPE 55.82% · Mejora vs Baseline: **+13.1%**. La tabla muestra métricas de TEST para comparar todos los modelos en igualdad de condiciones. Solo el ganador pasa a evaluarse en validación como confirmación final.

3.5 Optimización con Optuna — por qué y cómo

¿POR QUÉ XGBOOST Y NO LIGHTGBM O CATBOOST?

- XGBoost llegó a **998/1000 iteraciones sin hacer early stopping** → señal clara de que con más árboles o parámetros distintos puede mejorar
- LightGBM llegó a 999/1000 con el mismo comportamiento pero es 3× más lento
- XGBoost es el mejor balance entre precisión y eficiencia computacional

¿POR QUÉ SOLO 5M FILAS PARA LA BÚSQUEDA?

- Optuna ejecuta **30 trials** — cada trial entrena un modelo completo
- 57M × 30 trials = inviable computacionalmente
- Los últimos 5M filas son los más recientes → *más representativos del período a predecir*
- El modelo final se reentrena sobre el dataset completo (57M)

HIPERPARÁMETROS ENCONTRADOS POR OPTUNA Y SU INTERPRETACIÓN

Parámetro	Base	Optuna	Interpretación
n_estimators	1.000	**1.933**	El modelo necesitaba casi el doble de árboles
learning_rate	0.05	**0.023**	Aprendizaje más lento → más robusto, menos sobreajuste
max_depth	6	**8**	Alcanzó el límite superior → justifica árboles más profundos con 57M filas
min_child_weight	1	**31**	Regularización: mínimo 31 filas por hoja → evita sobreajuste en casos raros
gamma	0	**0.454**	Umbral de ganancia para dividir un nodo → poda el árbol
reg_alpha	0	**0.342**	Regularización L1 moderada sobre pesos de hojas
reg_lambda	1	**1.137**	Regularización L2 — prácticamente igual al base

3.6 Resultado Final y Validación

RMSE VALIDACIÓN	MEJORA VS BASELINE	MAPE VALIDACIÓN
1.8994	**+13.1%**	**55.82%**
Mejor resultado del proyecto	RMSE 2.1847 → 1.8994	Normal en retail item-día (M5: 40–70%)

¿Por qué el RMSE de validación (1.8994) es mejor que el de test (1.9645)?
Indica que el modelo **no sobreajusta** — generaliza bien a datos completamente nuevos. La mejora se debe a que los hiperparámetros Optuna (especialmente el learning rate más bajo y la regularización) favorecen la generalización. Validación es siempre el conjunto definitivo ya que *nunca fue visto durante entrenamiento ni optimización*.

3.7 Top 10 Features por Importancia (XGBoost+Optuna)

Rank	Feature	Tipo	Interpretación
#1	sales_rolling_mean_7	Histórico	Media de ventas últimos 7 días — tendencia más reciente (100% importancia relativa)
#2	sales_rolling_mean_14	Histórico	Media 14 días — tendencia a 2 semanas (28.6% importancia relativa)
#3	sales_rolling_mean_28	Histórico	Media 28 días — captura ciclo mensual y tendencia estable
#4	sales_lag_1	Histórico	Ventas ayer — alta autocorrelación directa
#5	sales_rolling_min_28	Histórico	Mínimo de ventas en 28 días — detecta productos con demanda intermitente
#6	is_weekend	Temporal	Efecto fin de semana — el factor externo más importante del modelo
#7	store_avg_sales	Producto/Tienda	Nivel base de ventas de la tienda — calibra la escala por ubicación
#8	weekday_int	Temporal	Día de la semana (0=lun, 6=dom) — complementa is_weekend con granularidad diaria
#9	sales_lag_21	Histórico	Ventas hace 3 semanas — captura ciclo semanal con 3 periodos de distancia
#10	sales_lag_28	Histórico	Ventas hace 4 semanas — estacionalidad mensual exacta

Los 10 primeros son variables históricas (rolling means, rolling min y lags) más el efecto fin de semana. Las variables de precio (price_rolling_mean_4w, price_lag_1) quedan en posiciones 11-14, confirmando que la demanda en retail de alimentación responde más al patrón histórico que al precio a corto plazo.

4. CONCLUSIONES Y VALOR APORTADO

Clustering

- k=5 productos: 5 perfiles claros (estrella, fin de semana, premium, regular, intermitente)
- k=3 tiendas: confirma que la **ciudad**

Forecasting

- XGBoost+Optuna: RMSE 1.8994 en **validación real no vista**
- Mejora del 13.1% sobre baseline — significativa

determina el comportamiento de ventas más que cualquier otra variable
- Permite estrategias diferenciadas de reposición sin analizar 30.490 combinaciones producto-tienda

en volumen de 57M predicciones
- MAPE 55.82% — dentro del rango normal de la competición M5 (Walmart) con datos similares
- Sin sobreajuste: validación mejor que test